

Московский авиационный институт
национальный исследовательский университет

Факультет информационных технологий и прикладной
математики

Кафедра компьютерных методов в математическом
моделировании сложных систем

**КУРСОВАЯ РАБОТА ПО ЭКОНОМЕТРИКЕ
НА ТЕМУ:
РЕГРЕССИОННЫЙ АНАЛИЗ**

Студент:
Преподаватель:
Группа:

Королев Егор Владимирович
Платонов Евгений Николаевич
М8О-401Б-18

Москва, 2021

Содержание

1	Задание	3
1.1	Теоретическая часть	3
1.2	Практическая часть	3
1.2.1	Модельная часть	3
1.2.2	Метод наименьших квадратов	3
1.2.3	Полиномиальная регрессия	4
1.2.4	Регрессия для наблюдений с выбросами	4
1.2.5	Квантильная регрессия	4
2	Байесовская регрессия	5
3	Практическая часть	5
3.1	Модельная часть	5
3.2	Метод наименьших квадратов	6
3.3	Полиномиальная регрессия	8
3.4	Регрессия для наблюдений с выбросами	8
3.5	Квантильная регрессия	8
4	Выводы	8

1 Задание

1.1 Теоретическая часть

Написать эссе по Байесовской регрессии.

1.2 Практическая часть

1.2.1 Модельная часть

Смоделировать данные:

$$X_k = f(h_k) + \varepsilon_k, \quad k = \overline{1, 60},$$

где $f(h) = 1.5h - 2 - \frac{1}{2h}$, $h \in [0.1; 2]$, ε_k – независимый случайные величины с распределением $\mathcal{N}(0, \sigma^2)$.

Точки внутри носителя для h выбираются равномерно.

Смоделировать тестовую выборку объема 40, половина значений правее наблюдаемых значений, половина левее

1.2.2 Метод наименьших квадратов

Для регрессии вида:

$$X_k = \theta_0 + \theta_1 h_k + \varepsilon_k, \quad k = \overline{1, 60}$$

- 1 Найти МНК-оценки неизвестных параметров;
- 2 построить график, на котором отобразить наблюдения, исходную функцию и линию регрессии;
- 3 вычислить коэффициент детерминации и найти оценку ковариационной матрицы МНК-оценки;
- 4 найти значения информационных критериев;
- 5 с помощью критерия Фишера проверить гипотезу: $\theta_0 = \theta_1 = 0$;
- 6 построить доверительный интервал надежности 0.95 и 0.8 для полезного сигнала $X = \theta_0 + \theta_1 h$ при h из исходного носителя $\pm 50\%$;
- 7 построить оценку метода наименьших модулей, отобразить ее на графике;
- 8 оценить качество построенных регрессий на тестовой выборке.

Для остатков $\hat{\varepsilon}_k = X_k - \hat{X}_k$:

- 1 построить гистограмму;
- 2 на графике изобразить ядерную оценку плотности распределения;
- 3 по остаткам проверить гипотезу, что $\hat{\varepsilon}$ имеет гауссово распределение с помощью одного из критериев:
 - критерий Шапиро-Уилка;
 - критерий D'Agostino K^2 ;
 - критерий Зарке-Бера;
- 4 проверить наличие автокорреляции с помощью критерия Дарбина-Уотсона;
- 5 проверить наличие гетероскедастичности с помощью одного из критериев;

1.2.3 Полиномиальная регрессия

Построить следующие регрессии с помощью МНК:

$$X = \sum_{i=0}^p \theta_i h^i$$

Порядок полинома p подобрать несколькими способами:

- 1 по значению среднеквадратичной погрешности МНК-оценки (на обучающей и/или тестовой);
- 2 по значению статистики критерия Фишера для гипотезы $\theta_p = 0$;
- 3 по MSE на тестовой выборке;
- 4 другим способом;

Для выбранного значения p :

- провести анализ остатков по схеме из пункта 2.2;
- построить график, на котором отобразить наблюдения, исходную функцию и линию регрессии;
- проверить для подобранной модели является ли матрица $H^T H$ мультиколлинеарной, если да, то построить оценку параметров с помощью метода редукции (ридж-оценка);

1.2.4 Регрессия для наблюдений с выбросами

Смоделировать ошибки для модели регрессии $X_k = \theta_0 + \theta_1 h_k + \varepsilon_k$ с помощью распределения Тьюки, приняв долю выбросов $\delta = 0.08$, номинальную регрессию $\sigma_0^2 = \sigma^2$, дисперсию аномальных наблюдений $\sigma_1^2 = 100\sigma^2$.

Построить МНК-оценку неизвестных параметров модели и оценить ее качество.

Провести анализ остатков по схеме их пункта 2.2.

Построить график, на котором отобразить наблюдения, исходную функцию и линию регрессии.

Провести отбраковку выбросов, пересчитать МНК-оценку и оценить качество оценки.

После отбраковки построить новый график, на котором отобразить наблюдения, исходную функцию и линию регрессии.

Провести анализ остатков по схеме их пункта 2.2.

Построить оценку метода наименьших модулей.

Построить график, на котором отобразить наблюдения, исходную функцию и линию регрессии метода наименьших модулей.

Провести анализ остатков по схеме их пункта 2.2.

Дополнительно: построить робастную оценку Хубера.

1.2.5 Квантильная регрессия

Смоделировать несимметричные ошибки для исходных данных, заменив у 90% отрицательных ошибок знак с минуса на плюс.

Построить МНК и МНМ оценки для получившихся наблюдений и регрессии.

Построить несколько квантильных регрессий (для различных значений параметра α) и оценить их качество.

Построить график, на котором отобразить наблюдения, исходную функцию и линии регрессий.

2 Байесовская регрессия

Байесовская регрессия

3 Практическая часть

3.1 Модельная часть

Для заданной функции $f(h) = 1.5h - 2 - \frac{1}{2h}$ смоделируем обучающую выборку $f(h_k) + \varepsilon_k$. Точки h_k выбраны равномерно на отрезке $[0.1; 2]$, изменяется от 1 до 60. Аналогично смоделируем тестовую выборку с количеством наблюдений равным 40. В качестве параметров нормального распределения ошибок ε было выбрано: $\mu = 0, \sigma = 1$. Тестовая выборка была сгенерирована только по одну сторону от обучающей, поскольку заданная функция имеет полюс первого порядка в точке $h = 0$, и, следовательно функция при приближении к этой точке быстро растет, поэтому при генерировании точек вблизи $h = 0$ значения могут быть крайне большими по модулю по сравнению с обучающей выборкой.




Рис. 1: Обучающая и валидационная выборки

3.2 Метод наименьших квадратов

Для модели простой линейной регрессии $X_k = \theta_0 + h\theta_1$ построим оценки МНК и МНМ, измерим качество, построенных моделей.




Рис. 2: Линии регрессии МНК и МНМ простой линейной регрессии

	МНК	МНМ
Уравнения прямых	$x = -3.63 + 2.25h$	$x = -3.34 + 2.12h$
R^2	0.55	0.55
RMSE	1.15	1.16
$\sum_i \varepsilon_i^2$ (на обуч. выборке)	78.87	80.58
$\sum_i \varepsilon_i^2$ (на тест. выборке)	44.22	43.63

Таблица 1: Сравнение моделей МНК и МНМ

Некоторые измерения модели с МНК.

Оценка ковариационной матрицы:

$$\hat{K} = \begin{pmatrix} 0.10 & -0.08 \\ -0.08 & 0.08 \end{pmatrix}$$

След оценки ковариационной матрицы $tr = 0.178$.

Функция логарифмического правдоподобия $l = -94.88$; информационный критерий Акаике $AIC = 0.39$; скорректированный (для малых выборок) $AIC_c = 0.6$; критерий Шварца $BIC = 197.95$.

Гипотеза, что $\forall i \theta_i = 0$ не принялась критерием Фишера на уровне значимости $\alpha = 0.05$. Гипотеза, что $\theta_n = 0$ не принялась критерием Фишера на уровне значимости $\alpha = 0.05$.

Для проверки мультиколлинеарности матрицы $H^T H$ был использован коэффициент инфляции дисперсии (VIF).

Для данной модели $VIF = (4.54, 1.0)$, следовательно проблема мультиколлинеарности методом VIF не обнаружена.




Рис. 3: Доверительные интервалы для X с надежностью 0.8 и 0.95

Анализ остатков.

Критерий Шапиро-Уилка: $T = 0.98, pvalue = 0.29$.

Гипотезу о нормальном распределении ошибок на уровне значимости 0.05 не удается принять.

Значение статистики Дарбина-Уотсона = 1.7.

Выборочный коэффициент корреляции $r = 0.15$.

Гипотеза о некоррелированности принимается.

Критерий Бройша-Пагана: $(T_1 = 2.08, pvalue_1 = 0.15), (T_2 = 2.08, pvalue_2 = 0.15)$.

Гипотеза о гетероскедастичности принимается на уровне значимости 0.05.




Рис. 4: Гистограмма ошибок




Рис. 5: Ядерные оценки плотности и распределения вероятности

3.3 Полиномиальная регрессия

3.4 Регрессия для наблюдений с выбросами

3.5 Квантильная регрессия

4 Выводы